

Programme d'Ingénierie en Intelligence Artificielle

– OC IA P5

Projet 5 – Segmentez les clients du site e-commerce de la société olist

Les comportements d'achat des clients varient et influencent les stratégies de vente.

C'est pourquoi olist souhaite segmenter ses clients en utilisant des méthodes d'apprentissage non supervisé pour identifier les différents types de clients.

Les objectifs incluent l'optimisation des campagnes marketing, l'amélioration de la satisfaction client, la fidélisation, une meilleure allocation des ressources, et des décisions stratégiques basées sur des insights précis.

Dans cette présentation, nous allons explorer le processus de segmentation des clients à travers l'utilisation d'algorithmes de clustering pour atteindre ces objectifs.

Sommaire

1. Processus de mise en place de la segmentation

2. Jeux de données

3. Exploration des données (EDA)

4. Insight clé (% de réachats)

5. Méthodologie et Visualisations

- Analyse RFM et algorithmes de clustering.
- Visualisations des segments.


6. Simulation de la maintenance des segments dans le temps

7. Conclusion

Préambule

- ➔ Cette présentation s'adresse à la fois aux professionnels du marketing et aux techniciens de la Data Science.
- ➔ Un compromis a été fait pour inclure des explications claires et accessibles tout en fournissant suffisamment de détails techniques.
- ➔ Aucun code n'est fourni dans cette présentation, mais les techniciens souhaitant plus d'informations peuvent consulter les notebooks pour des détails approfondis.
- ➔ Pour les non-datascientists, les questions lors de la présentation sont les bienvenues pour expliquer les concepts techniques.

1. Processus de mise en place de la segmentation.



1. Processus de mise en place de la segmentation (focus sur la normalisation).

La **normalisation** est cruciale pour l'analyse RFM (Récence, Fréquence, Montant) car elle évite qu'une métrique, comme le montant dépensé, domine le clustering.

Le graphique montre que la **distribution** des montants est très **asymétrique** (avant normalisation), avec des valeurs extrêmes.

Cela suggère que la **majorité des clients effectue des achats de faible valeur**.


Sans normalisation, **ces valeurs élevées peuvent fausser les clusters**, les rendant moins représentatifs des comportements réels des clients.

Normaliser assure que **chaque dimension** (récence, fréquence, montant) **contribue équitablement à la formation des clusters**, rendant la segmentation plus pertinente pour les décisions marketing.




2. Jeux de données

- **Jeux de données :**
 - Une base de donnée SQL avec les tables ci-dessous.
- **Clients :**
 - Segmentation des profils clients.
- **Commandes :**
 - Analyse des commandes par client.
- **Avis :**
 - Évaluation des avis par commande.
- **Produits :**
 - Étude des produits commandés.
- **Vendeurs :**
 - Profilage des vendeurs.
- **Géolocalisation :**
 - Analyse de la localisation des clients et des vendeurs.
- **Taille fichier final :**
 - 96,096 Clients (lignes)



3. Exploration des Données (EDA)




Les **5 catégories de produits les plus vendues** sont affichées dans le graphique en barres.

Les autres catégories étant regroupées sous « **Autres** ».

Les produits pour **le lit, le bain et la table** ont la plus grande part des ventes.

3. Exploration des Données (EDA)




Beauté et Santé a le score moyen d'avis le plus **élevé**, suivi de près par **Sports et Loisirs**.

La catégorie **Autres** a un score moyen **modéré**, indiquant une performance mixte.

Meubles et Décoration, Informatique et Accessoires, et Lit, Table et Bain ont des scores **plus bas**


3. *Exploration des Données (EDA)*



Sao Paulo a le plus grand nombre de clients, suivi par **Rio de Janeiro** et **Minas Gerais**.

Les **5 états principaux** regroupent la majorité des clients, les autres états étant classés sous "**Autres États**".

3. *Exploration des Données (EDA)*



La **majorité des paiements (76%)** sont effectués par **carte de crédit**, ce qui en fait le mode de paiement le plus utilisé. Le "Boleto" (ou Billet) est le deuxième mode de paiement le plus courant, représentant environ 19,9 % des transactions. Les "Vouchers" (ou Coupons) ne constituent qu'une petite fraction des paiements, avec seulement 3,9 % des transactions.


3. Exploration des Données (EDA)

Correlation between avg_review_score and days_early_or_late: -0.297663677189239



La corrélation entre le **score moyen des avis** et les **jours de retard** est de **-0,30**, montrant que les **retards de livraison** sont associés à des **scores plus bas**. Réduire les retards pourrait significativement améliorer la **satisfaction client**.

4. Insight clé (% de réachats)



Importance des 3% de Réachats dans la Méthodologie RFM et le Clustering :

Avec seulement **3%** de clients récurrents, la **fréquence** devient un facteur moins pertinent dans l'analyse.

Cette faible proportion de réachats suggère de se concentrer sur la **récence** et le **montant dépensé**.

Envisager d'**exclure la fréquence** pourrait améliorer la précision des segments et optimiser le clustering.

5.Méthodologie utilisée (Analyse RFM)

Recency (R) :

Temps écoulé depuis le dernier achat.

Frequency (F) :

Fréquence des achats par client.

Monetary (M) :

Montant total dépensé par client depuis le premier achat.

L'analyse RFM segmente les clients selon leur comportement d'achat, utile surtout pour les produits achetés régulièrement.

Limites de la segmentation RFM

Précision limitée : Seulement 3 groupes de variables (Récence, Fréquence, Montant).


Frequency peu différenciante : Majorité des clients avec une seule commande.

Dépendance aux scores : Résultats sensibles à l'affectation des scores RFM.

customer_unique_id	÷	Recency	÷	Frequency	÷	Monetary	÷	R	÷	F	÷	M	÷	RFMGroup	÷	RFMScore	÷	RFMLevel	÷
46450c74a0d8c5ca9395da1daac6c120		60		3		9553.02		1		1		1		111		3		Champions	
c8460e4251689ba205045f3ea17884a1		70		4		4655.91		1		1		1		111		3		Champions	
7b0eaf68a16e4808e5388c67345033c9		151		2		2340.08		1		1		1		111		3		Champions	
906a8a4ec9f3d4c3e64fa6d1c4fe6009		89		2		2020.86		1		1		1		111		3		Champions	
0341bbd5c969923a0f801b9e2d10a7b8		140		2		1999.68		1		1		1		111		3		Champions	
525cda9909aa001ebed396f6e55eae01		70		2		1782.90		1		1		1		111		3		Champions	
4facc2e6fbc2bffb2fea92d2b4aa7e4		64		4		1760.75		1		1		1		111		3		Champions	
397b44d5bb99eabf54ea9c2b41ebb905		121		4		1756.53		1		1		1		111		3		Champions	
87c9e7ba960e4c2e6bd786b162adc639		157		2		1653.98		1		1		1		111		3		Champions	
fe81bb32c243a86b2f86fbf053fe6140		118		5		1590.76		1		1		1		111		3		Champions	

Champions '111' : Achats fréquents, dépenses élevées, récence récente. RFMScore 3. Cruciaux pour le revenu et la fidélité. Fidélisez avec avantages exclusifs et offres personnalisées.

5. Méthodologie utilisée (K-Means sans normalisation).



➔ **K-means** - L'analyse effectuée sans normalisation a permis d'identifier la récence et le montant dépensé comme facteurs clés de la segmentation. 4 clusters ont été déterminés selon la méthode du coude

➔ **Fréquence :**

➔ Varie peu entre les clusters, donc non déterminante pour la segmentation.

➔ **Récence et revenu :**

➔ Les clients récents (cluster 1) génèrent le plus de revenus, un segment à cibler pour maximiser les gains à court terme.

➔ **Satisfaction :**

➔ Scores similaires entre les clusters, suggérant que récence et montant dépensé sont plus pertinents.

5. Méthodologie utilisée (K-Means avec Normalisation)

➤ **Clustering KMeans - Méthode du Coude pour Déterminer le Nombre Optimal de Clusters avec Normalisation Robustscaler des RFM**

➤ **KMeans Clustering :**

➤ Algorithme de regroupement qui partitionne les données en un nombre défini de clusters.



➤ **Méthode du Coude :**

➤ Technique pour déterminer le nombre optimal de clusters en observant le point où l'inertie commence à se stabiliser (forme de coude dans le graphique) indiquant un elbow autour de 3 et 4.

➤ La **méthode du score de silhouette** indique que le nombre optimal de clusters pour le jeu de données est de 3.

➤ **Normalisation Robustscaler :**


➤ Technique de normalisation qui réduit l'impact des outliers en centrant et réduisant les données selon les quartiles.



5. Méthodologie utilisée (K-Means visualisation des clusters)

➤ Visualisations des segments et des données supportant les insights avec le Clustering Kmeans (suite)

- **High Monetary, Varied Recency :**
Les clients avec une valeur monétaire élevée sont répartis sur l'axe de la récence, montrant que les achats importants ne sont pas exclusivement récents.
- **Low Monetary Cluster :** La majorité des clients ont une faible valeur monétaire, quelle que soit la récence.
- **Recommendation :**
Ciblez les clients à forte valeur monétaire avec des offres personnalisées, et engagez les clients à faible valeur pour augmenter leurs dépenses.



5. Méthodologie utilisé (DBScan – visualisation des clusters)

➔ Visualisations des segments et des données supportant les insights avec le Clustering DBScan

Observations du nuage de points 3D :


Densité centrale élevée : La majorité des utilisateurs partagent des caractéristiques similaires, regroupés près de l'origine.

Peu de clusters distincts : Les paramètres de DBSCAN semblent produire peu de clusters distincts.

Outliers : Quelques utilisateurs ont des comportements très différents des autres.

Faible récurrence des achats : La faible fréquence d'achats est confirmée par la concentration des points vers des valeurs faibles pour la fréquence.

Sensibilité de DBSCAN : La formation des clusters est fortement influencée par les paramètres.



5.Méthodologie utilisé (K-Means - Approche de clustering orientée business)

Étant donné que seulement 3 % des clients effectuent des achats répétés, nous pourrions adopter une **Approche de Clustering Orientée Business en collaboration avec l'équipe marketing** pour mieux aligner l'analyse avec les objectifs commerciaux. Cette approche se concentrerait sur les métriques les plus impactantes :


L'**approche par les poids avec K-means** ajuste l'importance de chaque variable pour orienter les clusters vers les dimensions les plus pertinentes pour les objectifs business.

Revenu (Monétaire) : Ajusté à 50 % pour cibler les clients générant le plus de revenus.

Fréquence : Augmenté à 35 % pour mettre en avant les achats récurrents, fortement corrélée avec la Valeur Vie Client (Customer Lifetime Value, CLV).

Récence : Réduit à 15 % pour surveiller les tendances d'engagement.

Cette méthode permettrait de cibler les segments de clients les plus précieux, maximisant ainsi la CLV et la croissance de l'entreprise.



5. Méthodologie utilisée (K-Means - Approche de clustering orientée business)

Observations des Résultats du Clustering :

Cluster 0 :

Grand nombre, faible revenu : La majorité des clients avec une contribution minimale aux revenus.

Cluster 1 :

Petite taille, revenu élevé : Peu de clients, mais un apport significatif en revenus.

Cluster 2 :

Taille moyenne, revenu élevé : Ces clients sont les plus précieux, générant le plus de revenus.

Recommandations

Cluster 0 : Augmenter la valeur de ces clients avec des promotions ou fidélisation.

Cluster 1 : Prioriser la fidélisation de ce segment clé.

Cluster 2 : Maximiser l'engagement et la fidélité de ces clients à haute valeur.



6. Simulation de la maintenance des segments dans le temps

Objectifs :

Assurer la stabilité et la précision du modèle de clustering dans le temps en surveillant ses performances et en le réentraînant si nécessaire. Cela implique :

Finaliser un Clustering Optimisé : S'assurer que le modèle de clustering est bien ajusté et pertinent du point de vue métier.

Simuler la Stabilité dans le Temps : Suivre la stabilité des clusters sur différentes périodes.

Score ARI élevé : Les clusters restent stables.

Score ARI faible : Les clusters deviennent moins cohérents, indiquant qu'une mise à jour du modèle pourrait être nécessaire.

Conclusion Finale :

Recalibrer les clusters tous les **trois mois** est recommandé pour maintenir la stabilité tout en évitant des ajustements inutiles. Cet intervalle assure une cohérence continue des clusters.



Explication du Graphique du Score ARI :

Le graphique montre la stabilité du modèle de clustering au fil du temps. Les **intervalles** sur l'axe des x représentent les moments où le modèle est réévalué (par exemple, tous les 30 jours 1er intervalle : Évaluation après 30 jours. 5ème intervalle : Évaluation après 150 jours (5 × 30 jours)).

7. conclusion

Dans ce projet pour **olist**, nous avons utilisé **KMeans** comme méthode principale de clustering, car elle s'est révélée plus performante que **DBSCAN**.

Une **approche orientée métier** a été retenue, où les **poids des variables** seraient **ajustés selon les objectifs commerciaux**, en collaboration avec l'équipe marketing. Cette méthode permettrait d'identifier des segments clients significatifs pour optimiser les stratégies marketing.

L'analyse exploratoire des données (**EDA**) a été cruciale pour identifier les variables clés, garantissant ainsi que les algorithmes de clustering sont bien alimentés. Un **contrat de maintenance** a été proposé, basé sur l'**ARI** (Adjusted Rand Index) pour surveiller la **stabilité des segments dans le temps**, avec la **possibilité d'utiliser l'apprentissage incrémental** pour adapter le modèle en cas d'ajout de nouveaux clients.

Conclusion principale : Une **collaboration** étroite entre les **équipes Data et Marketing**, combinée à une réévaluation régulière des segments, est essentielle pour maintenir une segmentation client efficace et alignée sur les **objectifs commerciaux d'Olist**.